




# 贝叶斯数据分析

## 贝叶斯数据分析笔记

作者：韩方成

组织：中国海洋大学水产学院

时间：Dec 5, 2021



光并非太阳的专利，你也可以发光

# 目录

<b>1</b>	<b>概率和推理</b>	<b>1</b>
1.1	贝叶斯数据分析的三大步骤	1
1.2	贝叶斯推理	1
1.2.1	概率符号	1
1.2.2	贝叶斯法则	1
1.2.3	预测	1
1.2.4	似然和比率	1
1.3	概率论中的一些有用的结果	2
1.3.1	变量的变换	2
<b>2</b>	<b>单参数模型</b>	<b>4</b>
2.1	从二项分布中估计概率	4
2.1.1	预测	4
2.2	后验作为数据和先验信息的折中	4
2.3	信息先验分布	5
2.3.1	具有不同先验分布的伯努利分布的例子	5
2.3.2	共轭先验分布	5
2.3.3	共轭先验分布、指数族和充分统计量	5
2.4	具有已知方差的正态分布	6
2.4.1	一个点的似然	6
2.4.2	共轭先验分布	6
2.4.3	先验和后验分布的精度	7
2.4.4	后验预测分布	7
2.4.5	具有多个观测的正态分布模型	7
2.5	其他标准单变量模型	8
2.5.1	均值已知但是方差未知的正态分布	8
2.5.2	泊松模型	8
2.5.3	负二项分布	9
2.5.4	根据 rate 和 exposure 参数化的泊松模型	9
2.5.5	指数模型	10
2.6	无信息 (Noninformative) 的先验分布	10
2.6.1	合适和不合适的先验分布	10
2.6.2	Jeffreys's invariance principle	10

---

<b>3 无信息先验分布</b>	<b>12</b>
3.1 广义先验分布 . . . . .	12
3.2 位置参数的无信息先验 . . . . .	13
<b>A Gamma, Beta 分布</b>	<b>14</b>
A.1 Gamma 函数 . . . . .	14
A.2 从二项分布到 Gamma 分布 . . . . .	16
A.3 认识 Beta/Dirichlet 分布 . . . . .	17
A.4 Beta-Binomial 共轭 . . . . .	19

# 第 1 章 概率和推理

## 1.1 贝叶斯数据分析的三大步骤

贝叶斯数据分析的过程可以被分为一下三步：

1. 建立全概率模型，即一个问题中所有可观测和不可观测的量的联合概率密度。
2. 计算后验概率：在给定已知数据下未知参数的分布。
3. 评估模型的拟合程度。

## 1.2 贝叶斯推理

### 1.2.1 概率符号

我们定义变异系数为  $\text{sd}(\theta)/E(\theta)$ ，几何平均数为  $\exp(E[\log(\theta)])$ ，并且几何标准差为  $\exp(\text{sd}[\log(\theta)])$ 。

### 1.2.2 贝叶斯法则

贝叶斯法则可以写为：

$$p(\theta|y) = \frac{p(\theta, y)}{p(y)} = \frac{p(\theta)p(y|\theta)}{p(y)} = \frac{p(\theta)p(y|\theta)}{\int_{\theta} p(\theta)p(y|\theta)d\theta} \quad (1.1)$$

因为在给定  $y$  的条件下  $p(y)$  为常数，与  $\theta$  无关，所以我们常将1.1写为式1.2所示的非标准化后验分布：

$$p(\theta|y) \propto p(\theta)p(y|\theta) \quad (1.2)$$

### 1.2.3 预测

为了对一个未知的可观测数据做预测，即预测推断。在数据  $y$  被考虑之前，未知但是可观测的  $y$  的分布为

$$p(y) = \int p(y, \theta)d\theta = \int p(\theta)p(y|\theta)d\theta \quad (1.3)$$

这被称为先验预测分布：先验是因为它没有以任何先前的观测为条件，预测是因为他是一个可观测数据的分布。

当数据  $y$  被观测到后，我们可以用同样的方式来预测一个未知可观测的  $\tilde{y}$ 。 $\tilde{y}$  的分布被称为后验预测分布，后验是因为它以观测  $y$  为条件，预测是因为他是可观测数据  $\tilde{y}$  的预测：

$$\begin{aligned} p(\tilde{y}|y) &= \int p(\tilde{y}, \theta|y)d\theta \\ &= \int p(\tilde{y}|\theta, y)p(\theta|y)d\theta \\ &= \int p(\tilde{y}|\theta)p(\theta|y)d\theta \end{aligned} \quad (1.4)$$

### 1.2.4 似然和比率

在给定模型下在点  $\theta_1$  和  $\theta_2$  的后验密度  $p(\theta|y)$  比值称为  $\theta_1$  相对于  $\theta_2$  的后验几率：

$$\frac{p(\theta_1|y)}{p(\theta_2|y)} = \frac{p(\theta_1)p(y|\theta_1)/p(y)}{p(\theta_2)p(y|\theta_2)/p(y)} = \frac{p(\theta_1)p(y|\theta_1)}{p(\theta_2)p(y|\theta_2)} \quad (1.5)$$

由此可以看出后验比率是先验比率和似然比例的乘积。

## 1.3 概率论中的一些有用的结果

我们经常用下列方式表示随机变量  $u$  的期望：

$$E(u) = E(E(u|v)) \quad (1.6)$$

公式1.6很好证明：

$$\iint up(u, v)dudv = \iint up(u|v)du p(v)dv = \int E(u|v)p(v)dv \quad (1.7)$$

方差包括两项：

$$\text{var}(u) = E(\text{var}(u|v)) + \text{var}(E(u|v)) \quad (1.8)$$

式1.8的证明为：

$$\begin{aligned} E(\text{var}(u|v)) + \text{var}(E(u|v)) &= E(E(u^2|v) - (E(u|v))^2) + E((E(u|v))^2) - (E(E(u|v)))^2 \\ &= E(u^2) - E((E(u|v))^2) + E((E(u|v))^2) - (E(u))^2 \\ &= E(u^2) - (E(u))^2 \\ &= \text{var}(u) \end{aligned}$$

### 1.3.1 变量的变换

如果  $p_u$  为一个离散分布，并且  $f$  为一个一对一的函数，而  $v = f(u)$ ，则  $v$  的概率密度为

$$p_v(v) = p_u(f^{-1}(v))$$

如果  $f$  是一个多对一函数，那么会对  $p_v(v)$  有一个求和。

如果  $p_u$  为一个连续分布且  $v = f(u)$  是一个一对一的函数，则

$$p_v(v) = |J|p_u(f^{-1}(v))$$

其中  $|J|$  为变换  $u = f^{-1}(v)$  的雅可比行列式，如果  $f$  为多对一函数，则  $p_v(v)$  上有积分或求和项。

当处理一维变量时，我们经常利用对数函数来将参数空间从  $(0, \infty)$  转换到  $(-\infty, \infty)$ 。当处理唯一开单位区间  $(0, 1)$  上的参数时，我们用 logistic 变换：

$$\text{logit}(u) = \log\left(\frac{u}{1-u}\right) \quad (1.9)$$

它的逆变换为：

$$\text{logit}^{-1}(v) = \frac{e^v}{1+e^v}$$

#### 定理 1.1

如果  $X$  是一个连续随机变量，并且它的累积概率密度函数为  $F_X$ ，则  $U = F_X(X) \sim U(0, 1)$



**证明** 在证明之前我们先定义：

$$F_X^{-1}(u) = \inf\{x : F_X(x) = u\}, 0 < u < 1$$

如果随机变量  $U \sim U(0, 1)$ , 则对于所有  $x \in \mathbb{R}$ :

$$\begin{aligned} P(F_X^{-1}(U) \leq x) &= P(\inf\{t : F_X(t) = U\} \leq x) \\ &= P(U \leq F_X(x)) \\ &= F_U(F_X(x)) \\ &= F_X(x) \end{aligned}$$

得证。

## 第2章 单参数模型

### 没有搞明白的章节

#### □ 章节2.6无信息先验分布

本节我们将介绍二项分布、高斯分布、泊松分布和指数分布的一维模型。

### 2.1 从二项分布中估计概率

一个二项分布模型为：

$$p(y | \theta) = \text{Bin}(y | n, \theta) = \binom{n}{y} \theta^y (1 - \theta)^{n-y} \quad (2.1)$$

我们假设  $\theta$  的先验分布为  $[0, 1]$  上的均匀分布，所以  $p(\theta) = 1^1$ 。又因为  $\binom{n}{y}$  为常数，所以将式1.1应用大式2.1，我们有：

$$p(\theta|y) \propto \theta^y (1 - \theta)^{n-y} \quad (2.2)$$

根据附录A关于 Beta 函数的讨论我们可知：

$$\theta|y \sim \text{Beta}(y + 1, n - y + 1) \quad (2.3)$$

#### 2.1.1 预测

假设我们现在预测抛一枚硬币为上的概率：

$$\begin{aligned} \Pr(\tilde{y} = 1|y) &= \int_0^1 \Pr(\tilde{y} = 1|\theta, y) p(\theta|y) d\theta \\ &= \int_0^1 \theta p(\theta|y) d\theta = E(\theta|y) = \frac{y + 1}{n + 2} \end{aligned} \quad (2.4)$$

### 2.2 后验作为数据和先验信息的折中

因为后验分布结合了数据的信息，它的方差应该比先验的要小。这个概念在下面的第二个表达式被形式化了：

$$E(\theta) = E(E(\theta|y)) \quad (2.5)$$

和

$$\text{var}(\theta) = E(\text{var}(\theta|y)) + \text{var}(E(\theta|y)) \quad (2.6)$$

这两个公式分别来自于式1.6和式1.8。从上面两个式子我们看出， $\theta$  的先验均值是所有可能后验均值的期望，并且后验方差的期望是小于先验方差的，其大小取决于后验均值的方差。也就是说，后验均值的方差越大， $\theta$  的不

<sup>1</sup>这里的  $p(y)$  也指概率密度函数，因为连续变量的贝叶斯公式为  $f_{\theta|y}(\theta|y) = \frac{f_{y|\theta}(y|\theta)f_{\theta}(\theta)}{f_y(y)}$



确定性减小得就越大。

## 2.3 信息先验分布

在上面关于 Beta 分布的例子，我们采用的先验分布是  $[0, 1]$  上的均匀分布，那么如果我们使用其他先验分布会怎样？

### 2.3.1 具有不同先验分布的伯努利分布的例子

考虑似然作为  $\theta$  的一个函数，其形式为：

$$p(y|\theta) \propto \theta^a(1-\theta)^b$$

因此如果先验分布是具有自己的  $a, b$  的相同形式的分布，那么后验分布也会有相同的形式。我们将这样的先验分布参数化为：

$$p(\theta) \propto \theta^{\alpha-1}(1-\theta)^{\beta-1}$$

为一个参数为  $\alpha, \beta$  的 Beta 分布： $\theta \sim \text{Beta}(\alpha, \beta)$ 。与似然函数相比，我们可以将先验密度看作是  $\alpha - 1$  次成功和  $\beta - 1$  次失败，先验分布的参数被称为超参数。超参数的选择将在之后涉及到。

现在假设我们已经可以选择合适的  $\alpha, \beta$ ，则  $\theta$  的后验分布密度为：

$$\begin{aligned} p(\theta | y) &\propto \theta^y(1-\theta)^{n-y}\theta^{\alpha-1}(1-\theta)^{\beta-1} \\ &\propto \theta^{y+\alpha-1}(1-\theta)^{n-y+\beta-1} \\ &= \text{Beta}(\theta | \alpha + y, \beta + n - y) \end{aligned}$$

先验和后验分布均为 Beta 分布，这样先验分布和后验分布具有相同的参数形式被称为共轭分布。

则后验分布的均值为：

$$E(\theta|y) = \frac{\alpha + y}{\alpha + \beta + n}$$

方差为

$$\text{var}(\theta|y) = \frac{(\alpha + y)(\beta + n - y)}{(\alpha + \beta + n)^2(\alpha + \beta + n + 1)} = \frac{E(\theta|y)[1 - E(\theta|y)]}{\alpha + \beta + n + 1}$$

实际上，在后面的章节中我们会详细介绍，根据中心极限定理我们有：

$$\left( \frac{\theta - E(\theta | y)}{\sqrt{\text{var}(\theta | y)}} \mid y \right) \rightarrow N(0, 1)$$

### 2.3.2 共轭先验分布

共轭定义如下。如果  $\mathcal{F}$  是一类抽样分布  $p(y|\theta)$ ，并且  $\mathcal{P}$  是  $\theta$  的一类先验分布，则  $\mathcal{P}$  对于  $\mathcal{F}$  是共轭的如果：

$$p(\theta|y) \in \mathcal{P} \text{ for all } p(\cdot|\theta) \in \mathcal{F} \text{ and } p(\cdot) \in \mathcal{P}$$

### 2.3.3 共轭先验分布、指数族和充分统计量

族  $\mathcal{F}$  被称为指数族如果它的所有成员都满足如下形式：

$$p(y_i|\theta) = f(y_i)g(\theta)e^{\phi(\theta)^T u(y_i)}$$



向量  $\phi(\theta)$  被称为族  $\mathcal{F}$  的自然参数 (natural parameter)。独立同分布的观测序列  $y = (y_1, \dots, y_n)$  的似然函数为：

$$p(y|\theta) = \left( \prod_{i=1}^n f(y_i) \right) g(\theta)^n \exp \left( \phi(\theta)^T \sum_{i=1}^n u(y_i) \right)$$

对于所有  $n$  和  $y$ ，这个有一个固定的形式：

$$p(y|\theta) \propto g(\theta)^n e^{\phi(\theta)^T t(y)}, \quad \text{where } t(y) = \sum_{i=1}^n u(y_i)$$

$t(y)$  被称为  $\theta$  的充分统计量，因为  $\theta$  的似然仅通过值  $t(y)$  依赖于数据  $y$ 。充分统计量在概率和后验分布的代数处理中是非常有用的。如果先验密度为：

$$p(\theta) \propto g(\theta)^\eta e^{\phi(\theta)^T v}$$

则后验分布为：

$$p(\theta|y) \propto g(\theta)^{\eta+n} e^{\phi(\theta)^T (v+t(y))}$$

## 2.4 具有已知方差的正态分布

### 2.4.1 一个点的似然

我们假设  $\sigma^2$  已知，则采样分布为：

$$p(y|\theta) = \frac{1}{\sqrt{2\pi\sigma}} e^{-\frac{1}{2\sigma^2}(y-\theta)^2}$$

### 2.4.2 共轭先验分布

作为  $\theta$  的函数，似然是  $\theta$  的二次指数形式，因此共轭先验分布族应该有如下形式：

$$p(\theta) = e^{A\theta^2 + B\theta + C}$$

我们将这个族参数化：

$$p(\theta) \propto \exp \left( -\frac{1}{2\tau_0^2} (\theta - \mu_0)^2 \right)$$

也就是， $\theta \sim N(\mu_0, \tau_0^2)$ 。其中  $\mu_0, \tau_0^2$  为超参数，我们假设它们已知。

则我们的后验分布为：

$$p(\theta|y) \propto \exp \left( -\frac{1}{2} \left( \frac{(y-\theta)^2}{\sigma^2} + \frac{(\theta - \mu_0)^2}{\tau_0^2} \right) \right)$$

整理后，我们有

$$p(\theta|y) \propto \exp \left( -\frac{1}{2\tau_1^2} (\theta - \mu_1)^2 \right) \quad (2.7)$$

也就是， $\theta|y \sim N(\mu_1, \tau_1^2)$ ，其中

$$\mu_1 = \frac{\frac{1}{\tau_0^2} \mu_0 + \frac{1}{\sigma^2} y}{\frac{1}{\tau_0^2} + \frac{1}{\sigma^2}} \quad \text{and} \quad \frac{1}{\tau_1^2} = \frac{1}{\tau_0^2} + \frac{1}{\sigma^2} \quad (2.8)$$

### 2.4.3 先验和后验分布的精度

我们通常称方差的倒数为精度，由式2.8可知，后验分布的均值可以看为先验分布和数据的加权平均，后验精度为先验精度和数据精度的和。我们也可以将后验均值拆成如下形式：

$$\begin{aligned}\mu_1 &= \mu_0 + (y - \mu_0) \frac{\tau_0^2}{\sigma^2 + \tau_0^2} \\ \mu_1 &= y - (y - \mu_0) \frac{\sigma^2}{\sigma^2 + \tau_0^2}\end{aligned}$$

因此我们可以得到：

$$\begin{aligned}\mu_1 &= \mu_0 \quad \text{if } y = \mu_0 \text{ or } \tau_0^2 = 0 \\ \mu_1 &= y \quad \text{if } y = \mu_0 \text{ or } \sigma^2 = 0\end{aligned}$$

### 2.4.4 后验预测分布

对于未来观测  $\tilde{y}$  的后验预测分布  $p(\tilde{y}|y)$ ，可以通过积分直接算出来：

$$\begin{aligned}p(\tilde{y}|y) &= \int p(\tilde{y}|\theta)p(\theta|y)d\theta \\ &= \int \exp\left(-\frac{1}{2\sigma^2}(\tilde{y} - \theta)^2\right) \exp\left(-\frac{1}{2\tau_1^2}(\theta - \mu_1)^2\right) d\theta\end{aligned}$$

我们知道  $E(\tilde{y}|\theta) = \theta$ ,  $\text{var}(\tilde{y}|\theta) = \sigma^2$ ，于是根据式1.6和1.8我们有：

$$E(\tilde{y}|y) = E(E(\tilde{y}|\theta, y)|y) = E(\theta|y) = \mu_1$$

和

$$\begin{aligned}\text{var}(\tilde{y} | y) &= E(\text{var}(\tilde{y} | \theta, y) | y) + \text{var}(E(\tilde{y} | \theta, y) | y) \\ &= E(\sigma^2 | y) + \text{var}(\theta | y) \\ &= \sigma^2 + \tau_1^2\end{aligned}$$

### 2.4.5 具有多个观测的正态分布模型

假设我们的数据  $y = (y_1, \dots, y_n)$  为独立同分布的。则后验密度为：

$$\begin{aligned}p(\theta | y) &\propto p(\theta)p(y | \theta) \\ &= p(\theta) \prod_{i=1}^n p(y_i | \theta) \\ &\propto \exp\left(-\frac{1}{2\tau_0^2}(\theta - \mu_0)^2\right) \prod_{i=1}^n \exp\left(-\frac{1}{2\sigma^2}(y_i - \theta)^2\right) \\ &\propto \exp\left(-\frac{1}{2}\left(\frac{1}{\tau_0^2}(\theta - \mu_0)^2 + \frac{1}{\sigma^2} \sum_{i=1}^n (y_i - \theta)^2\right)\right)\end{aligned}$$

后验分布仅仅通过采样均值  $\bar{y} = \frac{1}{n} \sum_i y_i$  与  $y$  有关，因此  $\bar{y}$  为充分统计量。事实上，根据中心极限定理，我们可知， $\bar{y}|\theta \sim N(\theta, \sigma^2/n)$ 。因此我们将  $\bar{y}$  看作是单个数据，我们有：

$$p(\theta|y_1, \dots, y_n) = p(\theta|\bar{y}) = N(\theta|\mu_n, \tau_n^2) \quad (2.9)$$

其中

$$\mu_n = \frac{\frac{1}{\tau_0^2}\mu_0 + \frac{n}{\sigma^2}\bar{y}}{\frac{1}{\tau_0^2} + \frac{n}{\sigma^2}} \quad \text{and} \quad \frac{1}{\tau_n^2} = \frac{1}{\tau_0^2} + \frac{n}{\sigma^2}$$

这个结果与每次只用一个数据是一样的。

## 2.5 其他标准单变量模型

### 2.5.1 均值已知但是方差未知的正态分布

对于  $p(y|\theta, \sigma^2) = N(y|\theta, \sigma^2)$ , 其中  $\theta$  已知  $\sigma^2$  未知, 对于  $n$  个独立同分布的观测序列  $y$  其似然函数为:

$$\begin{aligned} p(y|\sigma^2) &\propto \sigma^{-n} \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \theta)^2\right) \\ &= (\sigma^2)^{-n/2} \exp\left(-\frac{n}{2\sigma^2} v\right) \end{aligned}$$

充分统计量为:

$$v = \frac{1}{n} \sum_{i=1}^n (y_i - \theta)^2$$

相应的共轭先验分布是逆 Gamma 分布:

$$p(\sigma^2) \propto (\sigma^2)^{-(\alpha+1)} e^{-\beta/\sigma^2}$$

其超参数为  $\alpha, \beta$ 。一种方便的参数化方法是作为 scale 为  $\sigma_0^2$  自由度为  $\nu_0$  的 scaled 逆卡方分布<sup>2</sup>, 也就是说,  $\sigma^2$  的先验分布为分布  $\sigma_0^2 \nu_0 / X$ , 其中  $X$  为服从  $\chi_{\nu_0}^2$  的随机变量。为了方便我们使用非标准化的符号:  $\sigma^2 \sim \text{Inv} - \chi^2(\nu_0, \sigma_0^2)$ 。

则  $\sigma$  的后验分布为:

$$\begin{aligned} p(\sigma^2 | y) &\propto p(\sigma^2) p(y | \sigma^2) \\ &\propto \left(\frac{\sigma_0^2}{\sigma^2}\right)^{\nu_0/2+1} \exp\left(-\frac{\nu_0 \sigma_0^2}{2\sigma^2}\right) \cdot (\sigma^2)^{-n/2} \exp\left(-\frac{n}{2} \frac{v}{\sigma^2}\right) \\ &\propto (\sigma^2)^{-((n+\nu_0)/2+1)} \exp\left(-\frac{1}{2\sigma^2} (\nu_0 \sigma_0^2 + nv)\right) \end{aligned}$$

因此,

$$\sigma^2 | y \sim \text{Inv} - \chi^2\left(\nu_0 + n, \frac{\nu_0 \sigma_0^2 + nv}{\nu_0 + n}\right)$$

### 2.5.2 泊松模型

泊松分布在以计数形式研究数据时自然产生; 例如, 一个主要的应用领域是流行病学, 研究疾病的发病率。

如果数据点  $y$  服从参数为  $\theta$  的泊松分布, 则单个观察  $y$  的概率分布为:

$$p(y|\theta) = \frac{\theta^y e^{-\theta}}{y!}, \quad \text{for } y = 0, 1, 2, \dots$$

对于独立同分布的观测序列  $y = (y_1, \dots, y_n)$ , 似然函数为:

$$\begin{aligned} p(y|\theta) &= \prod_{i=1}^n \frac{1}{y_i!} \theta^{y_i} e^{-\theta} \\ &\propto \theta^{t(y)} e^{-n\theta} \end{aligned}$$

其中  $t(y) = \sum_{i=1}^n y_i$  为独立统计量。我们可以重现将其写为指数族的形式:

$$p(y|\theta) \propto e^{-n\theta} e^{t(y) \log \theta}$$

<sup>2</sup>不会翻译哈哈

这说明自然参数  $\phi(\theta) = \log \theta$ ，并且自然共轭先验为：

$$p(\theta) \propto (e^{-\theta})^\eta e^{v \log \theta}$$

超参数为  $(\eta, v)$ 。换句话说，似然函数的形式为  $\theta^A e^{-B\theta}$ ，因此共轭先验也必须有  $p(\theta) \propto \theta^A e^{-B\theta}$  的形式。我们用更方便的一种参数化形式：

$$p(\theta) \propto e^{\beta\theta} \theta^{\alpha-1}$$

为参数为  $\alpha, \beta$  的 Gamma 分布<sup>3</sup>。有了这样一个共轭先验分布，后验分布为：

$$\theta|y \sim \text{Gamma}(\alpha + n\bar{y}, \beta + n)$$

### 2.5.3 负二项分布

利用共轭族，已知后验分布和后验分布可以被用来找到边缘分布  $p(y)$ ，利用如下形式，

$$p(y) = \frac{p(y|\theta)p(\theta)}{p(\theta|y)}$$

例如，对于单个观测变量  $y$  的泊松模型， $y$  具有如下的先验预测分布：

$$\begin{aligned} p(y) &= \frac{\text{Poisson}(y|\theta) \text{Gamma}(\theta|\alpha, \beta)}{\text{Gamma}(\theta|\alpha + y, 1 + \beta)} \\ &= \frac{\Gamma(\alpha + y) \beta^\alpha}{\Gamma(\alpha) y! (1 + \beta)^{\alpha+y}} \end{aligned}$$

化简为：

$$p(y) = \binom{\alpha + y - 1}{y} \left( \frac{\beta}{\beta + 1} \right)^\alpha \left( \frac{1}{\beta + 1} \right)^y$$

这就是负二项分布：

$$y \sim \text{Neg-bin}(\alpha, \beta)$$

上述推导说明负二项分布为泊松分布的混合，其中泊松分布的参数  $\theta$  符合下列 Gamma 分布：

$$\text{Neg-bin}(y|\alpha, \beta) = \int \text{Poisson}(y|\theta) \text{Gamma}(\theta|\alpha, \beta) d\theta$$

### 2.5.4 根据 rate 和 exposure 参数化的泊松模型

在很多应用中，我们将泊松分布写为如下形式：

$$y_i \sim \text{Poisson}(x_i \theta) \quad (2.10)$$

其中  $x_i$  为已知的正解释变量， $\theta$  是未知的参数。在流行病学中， $\theta$  被称为 **rate**， $x_i$  被称为第  $i$  个单元的 **exposure**。则该模型的似然表示为：

$$p(y|\theta) \propto \theta^{\sum_{i=1}^n y_i} e^{-(\sum_{i=1}^n x_i) \theta}$$

因此 Gamma 分布的先验是共轭的。则后验分布为

$$\theta|y \sim \text{Gamma}\left(\alpha + \sum_{i=1}^n y_i, \beta + \sum_{i=1}^n x_i\right)$$

<sup>3</sup>Gamma 分布的期望为  $\frac{\alpha}{\beta}$ ，其方差为  $\frac{\alpha}{\beta^2}$

### 2.5.5 指数模型

指数分布通常用于模拟“等待时间”和其他连续的，正的，实值的随机变量，通常在时间尺度。在给定参数  $\theta$  下的  $y$  的采样概率为：

$$p(y|\theta) = \theta \exp(-y\theta), \text{ for } y > 0$$

并且  $\theta = 1/E(y|\theta)$  被称为 **rate**。

指数分布具有无记忆性，对象存活额外时间长度的概率与到目前为止所经过的时间无关，即  $\Pr(y > t+s|y > s, \theta) = \Pr(y > t|\theta)$ 。具有观测序列  $y = (y_1, \dots, y_n)$  的似然函数为：

$$p(y|\theta) = \theta^n \exp(-n\bar{y}\theta), \text{ for } \bar{y} \geq 0$$

。

## 2.6 无信息 (Noninformative) 的先验分布

### 2.6.1 合适和不合适的先验分布

我们回到估计已知方差为  $\sigma^2$  的正态模型的均值  $\theta$  的例子，它的先验分布为  $N(\mu_0, \tau_0^2)$ 。如果先验精度  $1/\tau_0^2$  相对于数据精度  $n/\sigma^2$  来说很小，则后验分布近似于

$$p(\theta|y) \approx N(\theta|\sigma^2/n)$$

但是这样的先验分布的积分不为 1<sup>4</sup>。一般来说，我们认为先验分布  $p(\theta)$  是合理的 (proper) 如果它不依赖于数据并且积分和为 1。本例中的先验分布是不合理的，但是后验分布是合理的。

### 2.6.2 Jeffreys's invariance principle

通过函数  $\phi = h(\theta)$  对参数进行一对一的变换，变换之后得到的先验分布  $p(\phi)$  与之前的先验分布  $p(\theta)$  表达同样的信息 (beliefs)。变换之后的先验分布为：

$$p(\phi) = p(\theta) \left| \frac{d\theta}{d\phi} \right| = p(\theta) |h'(\theta)|^{-1} \quad (2.11)$$

Jeffreys 的一般原则是，任何用于确定先验分布  $p(\theta)$  的规则应该与应用于变换参数产生等效的结果：也就是说，通过确定  $p(\theta)$  和应用变换 2.11 得到的  $p(\phi)$  应该与直接通过变换模型得到的结果相一致。

根据 Jeffreys 定理我们可以定义无信息先验密度为  $p(\theta) \propto [J(\theta)]^{1/2}$ ，其中  $J(\theta)$  为 Fisher 信息：

$$J(\theta) = E \left( \left( \frac{d \log p(y|\theta)}{d\theta} \right)^2 \middle| \theta \right) = -E \left( \frac{d^2 \log p(y|\theta)}{d\theta^2} \middle| \theta \right) \quad (2.12)$$

证明 Jeffreys 先验模型对于参数化是不变的，在  $\theta = h^{-1}(\phi)$  处计算  $J(\theta)$ ：

$$\begin{aligned} J(\phi) &= -E \left( \frac{d^2 \log p(y|\phi)}{d\phi^2} \right) \\ &= -E \left( \frac{d^2 \log p(y|\theta = h^{-1}(\phi))}{d\theta^2} \left| \frac{d\theta}{d\phi} \right|^2 \right) \\ &= J(\theta) \left| \frac{d\theta}{d\phi} \right|^2 \end{aligned} \quad (2.13)$$

<sup>4</sup>这样就相当于  $p(\theta)$  为常数，所以无穷积分不为 0

因此  $J(\phi)^{1/2} = J(\theta)^{1/2} \left| \frac{d\theta}{d\phi} \right|$ 。

## 第3章 无信息先验分布

以下基于西安交大梅长林老师的讲解。

假设我们没有任何先验信息可用，那么我们应该如何确定先验分布呢？

### 3.1 广义先验分布

贝叶斯假设：我们对  $\theta$  的任何取值都同等无知，无偏爱。即

$$p(\theta) = \begin{cases} c & \theta \in \Theta \\ 0 & \theta \notin \Theta \end{cases}$$

如果按照这种方法处理的话，我们很容易得到：

- 当  $\theta$  有可数个取值  $(\theta_1, \dots, \theta_m)$  时，则

$$p(\theta_i) = \frac{1}{m}$$

- 当  $\theta$  为  $(a, b)$  上的连续分布时，我们有

$$p(\theta) = \frac{1}{b-a}$$

但是这样就存在问题了，如果  $\theta$  的取值为可列集或者说  $(-\infty, \infty)$ ，那么我们就无法按照上述方式来定义其先验分布。那么我们需要对概念进行推广。

下面我们举一个例子，这个例子的先验分布不是一个正常的先验分布（积分不为1），但是他能得到一个正常的后验分布。

**例题 3.1** 设总体  $X \sim N(\theta, 1)$ ,  $-\infty < \theta < +\infty$ ，我们设先验分布为  $p(\theta) = c$ 。则

$$\begin{aligned} p(\theta|x) &= \frac{p(x|\theta)p(\theta)}{\int_{-\infty}^{\infty} p(x|\theta)p(\theta)d\theta} \\ &= \frac{\frac{1}{\sqrt{2\pi}}e^{-\frac{(x-\theta)^2}{2}}c}{\int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}}e^{-\frac{(x-\theta)^2}{2}}cd\theta} \\ &= \frac{1}{\sqrt{2\pi}}e^{-\frac{(x-\theta)^2}{2}} = N(x, 1) \end{aligned}$$

由此可以看出，虽然先验分布不是正常的分布，但是得到的后验分布确是正常的分布。

我们要做的就是寻找和上述例子相似的先验分布，即广义先验分布。

#### 定义 3.1 (广义先验分布)

设总体  $X \sim p(x|\theta)$ 。若  $\theta$  的先验分布满足：

- $p(\theta) \geq 0, \int_{\Theta} p(\theta)d\theta = +\infty$
- 有  $p(\theta)$  确定的后验分布  $p(\theta|x)$  是正常的概率分布。

我们就称  $p(\theta)$  为广义先验分布。



但是贝叶斯假设还存在一个缺陷，就是它对变量变换不具有不变性。

**例题 3.2** 假设  $X \sim N(0, \sigma^2)$ ，我们假设  $\theta = \sigma, \theta \in (0, +\infty)$ ，而  $\eta = \sigma^2, \eta \in (0, +\infty)$ 。我们可以看出  $\theta$  和  $\eta$  是一一对应的，也就说这样的变换并不损失信息。根据贝叶斯假设  $p(\theta) = c, p(\eta) = c'$ 。但是根据概率密度变量的变换



的公式，我们有

$$p(\eta) = p(\sqrt{\eta}) \left| \frac{d\theta}{d\eta} \right| = \frac{1}{2\sqrt{\eta}} p(\sqrt{\eta}) = \frac{1}{2\sqrt{\eta}} c$$

。显然不是常数。于是违背了贝叶斯假设。

## 3.2 位置参数的无信息先验

### 定义 3.2 (位置参数)

若概率密度族有如下形式：

$$\{p(x - \theta), -\infty < \theta < +\infty\}$$

则称它为位置参数族，参数  $\theta$  被称为位置参数。



**例题 3.3** 设  $X \sim p(x - \theta)$ 。令  $Y = X + c, \eta = \theta + c$ 。则对于  $Y: p(y - c - \theta) = p(y - \eta)$ ，所以  $Y$  的分布仍为位置参数族的成员，所以  $(x, \theta)$  和  $(y, \eta)$  的统计问题结构是相同的，所以它们先验分布的结构也应该是相同的。那么  $p(\theta)$  也应该具有位置不变性。也就是说  $p(\theta) = p(\theta + c)$ ，对于任意  $c$ ，所以其先验分布应该为常数，我们常把常数设为 1，即  $p(\theta) = 1$ 。

下面证明为什么先验分布为常数：

**证明** 我们令  $\eta = \theta + c$ ，则：

$$p(\eta) = p(\theta) \cdot \left| \frac{d\theta}{d\eta} \right| = p(\eta - c)$$

又因为  $c$  为任意常数，所以  $p(\theta)$  为常数。

## 第 A 章 Gamma, Beta 分布

以下内容基于 LDA 的数学八卦。

### A.1 Gamma 函数

#### 定义 A.1 (Gamma 函数)

$$\Gamma(x) = \int_0^{\infty} t^{x-1} e^{-t} dt \quad (\text{A.1})$$

通过分布积分的方法，可以推导出这个函数有如下的递归性质：

$$\Gamma(x+1) = x\Gamma(x)$$

于是很容易证明， $\Gamma(x)$  函数可以当成是阶乘在实数集上的延拓，具有如下性质：

$$\Gamma(n) = (n-1)!$$



那么 Gamma 函数是怎么来的呢？这个来源于哥德巴赫在将阶乘推广到实数域的问题上，欧拉解决了这个问题，他发现  $n!$  可以用如下的一个无穷乘积表达：

$$\left[ \left( \frac{2}{1} \right)^n \frac{1}{n+1} \right] \left[ \left( \frac{3}{2} \right)^n \frac{2}{n+2} \right] \left[ \left( \frac{4}{3} \right)^n \frac{3}{n+3} \right] \cdots = n! \quad (\text{A.2})$$

用极限形式，这个式子整理后可以写为

$$\lim_{m \rightarrow \infty} \frac{1 \cdot 2 \cdot 3 \cdots m}{(1+n)(2+n) \cdots (m+n)} (m+1)^n = n! \quad (\text{A.3})$$

左边可以整理为：

$$\begin{aligned} & \frac{1 \cdot 2 \cdot 3 \cdots m}{(1+n)(2+n) \cdots (m+n)} (m+1)^n \\ &= 1 \cdot 2 \cdot 3 \cdots n \cdot \frac{(n+1)(n+2)m}{(1+n)(2+n) \cdots m} \cdot \frac{(m+1)^n}{(m+1)(m+2) \cdots (m+n)} \\ &= n! \frac{(m+1)^n}{(m+1)(m+2) \cdots (m+n)} \\ &= n! \prod_{k=1}^n \frac{m+1}{m+k} \rightarrow n! \quad (m \rightarrow \infty) \end{aligned}$$

所以上式成立。

之后欧拉对得到的式子进行了处理，得到了积分的形式：

$$n! = \int_0^1 (-\log t)^n dt$$

如果我们令  $t = e^{-u}$ ，就可得我们常见的 Gamma 函数形式：

$$n! = \int_0^{\infty} u^n e^{-u} du$$

于是，利用上式把阶乘延拓到实数集上，我们就得到了 Gamma 函数的一般形式：

$$\Gamma(x) = \int_0^{\infty} t^{x-1} e^{-t} dt$$

Gamma 函数不仅可以用来计算  $(1/2)!$ ，还可以拓展到许多其他的数学概念。比如导数，我们可以把导数的定义

拓展到实数集，从而可以计算  $1/2$  阶导数。我们考虑  $x^n$  的导数，我们知道， $x^n$  的  $k$  阶导数为：

$$n(n-1)(n-2)\cdots(n-k+1)x^{n-k} = \frac{n!}{(n-k)!}x^{n-k}$$

由于  $k$  阶导数可以用阶乘表达，于是我们用 Gamma 函数表达式为：

$$\frac{\Gamma(n+1)}{\Gamma(n-k+1)}x^{n-k}$$

于是基于上式，我们可以把导数的阶从整数延拓到实数集。例如，取  $n=1, k=\frac{1}{2}$ ，我们可以计算  $x$  的  $\frac{1}{2}$  阶导数为：

$$\frac{\Gamma(1+1)}{\Gamma(1-1/2+1)}x^{1-1/2} = \frac{2\sqrt{x}}{\sqrt{\pi}}$$

Gamma 函数的图像如图A.1所示，由此可以看出 Gamma 函数为一个凸函数。不仅如此， $\log(\Gamma(x))$  也是一个凸函数。




图 A.1:  $\Gamma(x)$

数。我们可以用以下定理证明：

**定理 A.1 (Bohr-Mullerup)**

如果  $f: (0, \infty) \rightarrow (0, \infty)$ ，且满足

1.  $f(1) = 1$
2.  $f(x+1) = xf(x)$
3.  $\log f(x)$  是凸函数

那么  $f(x) = \Gamma(x)$ ，也就是  $\Gamma(x)$  是唯一满足以上条件的函数。



如下函数被称为 Digamma 函数，

$$\Psi(x) = \frac{d \log \Gamma(x)}{dx}$$

这也是一个很重要的函数，在涉及求 Dirichlet 分布相关的参数的极大似然估计时，往往需要用到这个函数。Digamma 函数具有如下一个漂亮的性质：

$$\Psi(x+1) = \Psi(x) + \frac{1}{x}$$

## A.2 从二项分布到 Gamma 分布

对 Gamma 函数的定义做一个变形，就可以得到如下式子：

$$\int_0^{\infty} \frac{x^{\alpha-1} e^{-x}}{\Gamma(\alpha)} dx = 1$$

于是，取积分中的函数作为概率密度，就得到一个形式最简单的 Gamma 分布的密度函数：

$$\text{Gamma}(x|\alpha) = \frac{x^{\alpha-1} e^{-x}}{\Gamma(\alpha)}$$

如果做一个变换  $x = \beta t$ ，就得到 Gamma 分布的更一般形式

$$\text{Gamma}(t|\alpha, \beta) = \frac{\beta^{\alpha} t^{\alpha-1} e^{-\beta t}}{\Gamma(\alpha)}$$

其中  $\alpha$  为 shape parameter，主要决定分布曲线的形状，而  $\beta$  称为 rate parameter 或者 inverse scale parameter ( $\frac{1}{\beta}$  被称为 scale parameter)，主要决定曲线有多陡。如图A.2所示。




图 A.2:  $\Gamma$  分布

下面我们先讨论  $\beta = 1$  情况。Gamma 分布首先与 Poisson 分布、Poisson 过程发生密切的联系。参数为  $\lambda$  的 Poisson 分布，概率写为：

$$\text{Poisson}(X = k|\lambda) = \frac{\lambda^k e^{-\lambda}}{k!}$$

在 Gamma 分布的密度函数取  $\alpha = k + 1$  得到

$$\text{Gamma}(x|\alpha = k + 1) = \frac{x^k e^{-x}}{k!}$$

所以这两个分布数学形式上是一样的。这个并不是偶然的。我们在数理统计中学过， $\text{Poisson}(\lambda)$  可以看作是二项分布  $B(n, p)$  在  $np = \lambda, n \rightarrow \infty$  条件下的极限分布。其实二项分布的随机变量  $X \sim B(n, p)$  满足如下一个很奇妙的恒等式：

$$P(X \leq k) = \frac{n!}{k!(n-k-1)!} \int_p^1 t^k (1-t)^{n-k-1} dt \quad (\text{A.4})$$

我们之后再证明它。我们先暂且承认A.4是成立的。我们在等式右边做一个变换  $t = \frac{x}{n}$  得到：

$$\begin{aligned} P(X \leq k) &= \frac{n!}{k!(n-k-1)!} \int_p^1 t^k (1-t)^{n-k-1} dt \\ &= \frac{n!}{k!(n-k-1)!} \int_{np}^n \left(\frac{x}{n}\right)^k \left(1 - \frac{x}{n}\right)^{n-k-1} d\frac{x}{n} \\ &= \frac{(n-1)!}{k!(n-k-1)!} \int_{np}^n \left(\frac{x}{n}\right)^k \left(1 - \frac{x}{n}\right)^{n-k-1} dx \\ &= \int_{np}^n \binom{n-1}{k} \left(\frac{x}{n}\right)^k \left(1 - \frac{x}{n}\right)^{n-k-1} dx \\ &= \int_{np}^n \text{Binomial}\left(Y = k \mid n-1, \frac{x}{n}\right) dx \end{aligned} \quad (\text{A.5})$$

于是我们有：

$$\text{Binomial}(X \leq k \mid n, p) = \int_{np}^n \text{Binomial}(Y = k \mid n-1, \frac{x}{n}) dx \quad (\text{A.6})$$

我们对式A.6在条件  $np = \lambda, n \rightarrow \infty$  下取极限，则左边有  $B(n, p) \rightarrow \text{Poisson}(\lambda)$ ，而右边有  $B(n-1, \frac{x}{n}) \rightarrow \text{Poisson}(x)$ ，所以得到：

$$\text{Poisson}(X \leq k \mid \lambda) = \int_{\lambda}^{\infty} \text{Poisson}(Y = k \mid x) dx \quad (\text{A.7})$$

把上式右边的 Poisson 分布展开，得到：

$$\text{Poisson}(X \leq k \mid \lambda) = \int_{\lambda}^{\infty} \frac{x^k e^{-x}}{k!} dx \quad (\text{A.8})$$

在  $\lambda \rightarrow 0$  情况下取极限，得：

$$1 = \int_0^{\infty} \frac{x^k e^{-x}}{k!} dx$$

这就得到了 Gamma 函数，另外

$$k! = \int_0^{\infty} x^k e^{-x} dx$$

即  $k!$  的积分表示方法。

最后我们将式A.8变形一下，得到：

$$\text{Poisson}(X \leq k \mid \lambda) + \int_0^{\lambda} \frac{x^k e^{-x}}{k!} dx = 1$$

由此可以看出 Poisson 分布的累积概率和 Gamma 分布的累积概率具有互补的性质。

## A.3 认识 Beta/Dirichlet 分布

假设我们现在有这样一个问题：

1.  $X_1, X_2, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Uniform}(0, 1)$
2. 把这  $n$  各随机变量排序后得到顺序统计量  $X_{(1)}, X_{(2)}, \dots, X_{(n)}$
3. 问  $X_{(k)}$  的分布是什么

我们尝试先计算一下  $X_{(k)}$  落在一个区间  $[x, x + \Delta x]$  的概率，也就是以下概率取值：

$$P(x \leq X_{(k)} \leq x + \Delta x) = ?$$

我们把区间  $[0, 1]$  分为三段  $[0, x], [x, x + \Delta x], (x + \Delta x, 1]$ ，我们先考虑简单的情形，假设  $n$  个数只有一个落在区间  $[x, x + \Delta x]$  内，则因为这个区间内的数  $X_{(k)}$  是第  $k$  大的，则  $[0, x]$  中应有  $k - 1$  个数， $(x, 1]$  区间应该有  $n - k$  个数。不失一般性，我们先考虑如下一个符合上述要求的事件  $E$ ：

$$X_1 \in [x, x + \Delta x],$$

$$E = X_i \in [0, x) \quad (i = 2, \dots, k)$$

$$X_j \in (x + \Delta x, 1] \quad (j = k + 1, \dots, n)$$

如图A.3所示。则有：




图 A.3: 事件  $E$

$$\begin{aligned} P(E) &= \prod_{i=1}^n P(X_i) \\ &= x^{k-1} (1 - x - \Delta x)^{n-k} \Delta x \\ &= x^{k-1} (1 - x)^{n-k} \Delta x + o(\Delta x) \end{aligned}$$

显然，由于不同的排列组合，即  $n$  个数中有一个落在  $[x, x + \Delta x]$  区间的有  $n$  种取法，余下  $n - 1$  数中有  $k - 1$  个落在  $[0, x)$  的有  $\binom{n-1}{k-1}$ ，所以与  $E$  等价的事件一共有  $n \binom{n-1}{k-1}$  个。

下面我们考虑一个更为复杂的情况，假设  $n$  个数中有两个数落在了区间  $[x, x + \Delta x]$ ，

$$X_1, X_2 \in [x, x + \Delta x],$$

$$E' = X_i \in [0, x) \quad (i = 3, \dots, k)$$

$$X_j \in (x + \Delta x, 1] \quad (j = k + 1, \dots, n)$$

则有：

$$P(E') = x^{k-2} (1 - x - \Delta x)^{n-k} (\Delta x)^2 = o(\Delta x)$$

所以只有落入  $[x, x + \Delta x]$  内的数字超过一个，对应的概率就是  $o(\Delta x)$ 。于是：

$$\begin{aligned} P(x \leq X_{(k)} \leq x + \Delta x) &= n \binom{n-1}{k-1} P(E) + o(\Delta x) \\ &= n \binom{n-1}{k-1} x^{k-1} (1 - x)^{n-k} \Delta x + o(\Delta x) \end{aligned}$$

所以，可以得到  $X_{(k)}$  的概率密度函数为：

$$\begin{aligned} f(x) &= \lim_{\Delta x \rightarrow 0} \frac{P(x \leq X_{(k)} \leq x + \Delta x)}{\Delta x} \\ &= n \binom{n-1}{k-1} x^{k-1} (1-x)^{n-k} \\ &= \frac{n!}{(k-1)!(n-k)!} x^{k-1} (1-x)^{n-k} \quad x \in [0, 1] \end{aligned}$$

，利用 Gamma 我们可以将  $f(x)$  的表达式写为：

$$f(x) = \frac{\Gamma(n+1)}{\Gamma(k)\Gamma(n-k+1)} x^{k-1} (1-x)^{n-k}$$

我们在上式中取  $\alpha = k, \beta = n - k + 1$ ，于是我们得到：

$$f(x) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} x^{\alpha-1} (1-x)^{\beta-1} \quad (\text{A.9})$$

这就是一般意义上的 Beta 分布。

## A.4 Beta-Binomial 共轭

假设我们的问题变为：

1.  $X_1, X_2, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Uniform}(0, 1)$ ，排序后对应的顺序统计量  $X_{(1)}, X_{(2)}, \dots, X_{(n)}$ ，我们要猜测  $p = X_{(k)}$
2.  $Y_1, Y_2, \dots, Y_m \stackrel{\text{iid}}{\sim} \text{Uniform}(0, 1)$ ， $Y_i$  中有  $m_1$  个比  $p$  小， $m_2$  个比  $p$  大
3. 问  $P(p|Y_1, Y_2, \dots, Y_m)$  的分布是什么。

由于  $p = X_{(k)}$  在  $X_1, X_2, \dots, X_n$  中是第  $k$  大的，利用  $Y_i$  的信息，我们容易推理得到  $p = X_{(k)}$  在  $X_1, X_2, \dots, X_n, Y_1, Y_2, \dots, Y_m \stackrel{\text{iid}}{\sim} \text{Uniform}(0, 1)$  这  $(m+n)$  个独立随机变量中是第  $k+m_1$  大的，于是按照上一个小组的推理，此时  $p = X_{(k)}$  的概率密度函数是  $\text{Beta}(p|k+m_1, n-k+1+m_2)$ 。按照贝叶斯推理的过程，我们可以把以上过程表述为：

1.  $p = X_{(k)}$  是我们猜测的参数，我们推导出  $p$  的分布为  $f(p) = \text{Beta}(p|k, n-k+1)$ ，称为  $p$  的先验分布
2. 数据  $Y_i$  中有  $m_1$  个比  $p$  小， $m_2$  个比  $p$  大， $Y_i$  相当于是做了  $m$  次贝努力实验，所以  $m_1$  服从二项分布  $B(m, p)$
3. 在给定了来自数据提供的  $(m_1, m_2)$  的知识后， $p$  的后验分布变为  $f(p|m_1, m_2) = \text{Beta}(p|k+m_1, n-k+1+m_2)$

上述可以表示为：

$$\text{Beta}(p|\alpha, \beta) + \text{BinomCount}(m_1, m_2) = \text{Beta}(p|\alpha + m_1, \beta + m_2) \quad (\text{A.10})$$

这个式子描述的就是 Beta-Binomial 共轭。从上面过程我们可以看到，Beta 分布中的  $\alpha, \beta$  参数都可以理解为物理计数，这两个参数经常被称为伪计数。基于以上逻辑，我们也可以把  $\text{Beta}(p|\alpha, \beta)$  写成下式来理解：

$$\text{Beta}(p|1, 1) + \text{BinomCount}(\alpha - 1, \beta - 1) = \text{Beta}(p|\alpha, \beta) \quad (\text{A.11})$$

其中  $\text{Beta}(0, 1)$  恰好就是  $[0, 1]$  上的均匀分布。